

MIMIC: Integrating Diverse Personality Traits for Better Game Testing Using Large Language Model

Yifei Chen, Sarra Habchi, Lili Wei



概要

- 多様なパーソナリティをゲームエージェントに統合し、より多様で効果的なゲームテストを可能にするフレームワークMIMICを提案

概要

- オープンソースゲーム

Dungeon Adventures

Shattered Pixel Dungeon

を使用

コードレベル及びインタラクションレベル

カバレッジで有効性を評価

さらに商用ゲームMinecraftにおいて

タスク完了率で評価

背景

- LLMのための検索拡張生成
大規模言語モデルの「ハルシネーション」を軽減し
効率を向上させるため、検索拡張生成(RAG)が導入

背景

- ゲーマー特性のモデル化
最新の研究(PathOS)で、ゲーマーの行動は7つの特性、
達成、アドレナリン、攻撃性、慎重さ、完遂、
好奇心、効率性へ統合
→これらの特性を活用して、人間の行動を模倣させる
プロンプトを作成


既存研究の問題点

- 既存研究は、タスクの完了に最適化されていてしばしば同質的な反復行動を生み出す
 - その結果、多様性と適応性を模倣できずゲームテストにおける全体的な有効性が低下


本研究の目的

- パーソナリティを模倣し、多様な行動をとるエージェントを用いたテストのコードのカバレッジの上昇やタスクの完了率といった有効性を検証する

手法(1/5)




手法(2/5)



Planner (中核モジュール)

- 性格特性から行動計画を生成 → 多様で人間らしいプレイを再現
- ハイブリッド計画：低レベルの即応行動 ⇔ 高レベルの目標分解を切替
- 入力：性格特性・ゲーム環境・過去の計画（Memoryから取得）


手法(3/5)



Action Summarizer

- 各イテレーションの実行が計画を達成できたか評価
- Prompt Chaining：期待結果を予測 → 実結果と比較
- CoTで根拠付きの要約を生成し Memory へ保存


手法(4/5)



Action Executor

- 計画をゲームで実行可能な形式へ変換
- Plan-to-Code : API を組み合わせたコード (Skill) を生成 (例 : Minecraft)
- Plan-to-Parameters : API パラメータへ直接変換

手法(5/5)



Memory System (非LLM)

- 行動・環境・要約を「記憶」として蓄積
- RAG で関連する記憶だけ取得（トークン削減・幻覚抑制）
- 3種の検索：好みの計画／関連記憶／Skill


RQ

- RQ1：MIMICはコードカバレッジの達成においてどれだけ効果的か？
- RQ2：MIMICはゲーム内の多様な挙動・インタラクションのカバーにおいてどれだけ効果的か？

RQ

- RQ3：与えられたタスクの遂行において、MIMICは最先端(SOTA)ツールと比べてどの程度の性能か？
- RQ4：与えられたタスクの解決において、MIMICの解法は既存ツールと比べてどれだけ多様であるか？

有効性評価 (RQ1 & RQ2)



実験設定：対象ゲームと環境

項目	Dungeon Adventures (DA)	Shattered Pixel Dungeon (SPD)
種類	小規模ターン制RPG	大規模ローグライクRPG
規模	4レベル / 4アイテム / 4敵	25レベル / 250+アイテム / 65+敵
マップ	固定	ランダム生成（シード指定）
テスト目標	ボスを倒す	ダンジョンを踏破する
制限時間	1.5時間（人間は1時間）	4時間

LLM：GPT-4o（2024-08-06, API経由）／ 実行環境：Windows 11・Intel i7-10750H・32GB RAM
全実験：3回反復 × 7パーソナリティ = 21実行（自動ツールも同条件）

ベースライン：比較対象の5手法

アブレーション版

MIMIC-P
LLM Plannerのみ

MIMIC-P+S
+ Summarizer
(メモリ・個性なし)

人間ベースライン

7名の熟練テスター

ゲーム経験5年以上
週平均6.8時間

手動テスト
(開発の一般的慣行)

ランダム (Monkey)

Dumb Monkey
無制約にAPIを呼出

Smart Monkey
妥当なアクション
のみを実行

評価メトリクス(2階層)

コードレベル

内部ロジックの実行度を測定

- コードカバレッジ
実行されたコード行の割合
- 分岐カバレッジ
実行された分岐の割合

※ JaCoCoで測定／UIコードは除外



インタラクションレベル

ゲーム世界との関わり方を測定

- 組合せカバレッジ
アクション×最大4パラメータの組合せ
- ナビゲーションカバレッジ
到達可能な場所の探索率


※ 行動起因のバグを可視化

RQ1：コードレベルの有効性





Dungeon Adventures (DA) のコードカバレッジ (左) と分岐カバレッジ (右)

RQ1：コードレベルの有効性



Shattered Pixel Dungeon (SPD) の時間経過に伴うコードカバレッジ（左）と分岐カバレッジ（右）


RQ1：コードレベルの有効性



Shattered Pixel Dungeon (SPD) のアクション反復に伴うコードカバレッジ（左）と分岐カバレッジ（右）


RQ1：コードレベルの有効性

最終カバレッジ (%) : MIMIC vs 人間




- DA：35分以内に最高値
Code 95.67% / Branch 92.77%
- Monkeyの1.16倍
アブレーション版も上回る
- SPD：全自動ツールで最高
Smart Monkeyより平均 +3%
($\div$ +11,776行)
- 人間(59.97%)には規模ゆえ未達

RQ2：組み合わせカバレッジ



(a) Combinatorial Coverage in DA



(b) Combinatorial Coverage in SPD

Dungeon Adventures (DA) の組合せカバレッジ (左) と、
Shattered Pixel Dungeon (SPD) の対数スケールのカバレッジ (右)

RQ2：組み合わせカバレッジ


Dungeon Adventures

100%

72組合せを全網羅（自動ツール最高）

- Monkeyの 1.5倍
- アブレーション版を超える
(P: $\times 1.18$ / P+S: $\times 1.07$)

SPD 組合せカバレッジ (%)



SPD：全1130万組合せ中 21,319 をカバー。Smart Monkeyの2.51倍で、4時間飽和せず改善。

RQ2：ナビゲーションカバレッジと信頼区間

テストツール	DA 探索Lv	DA ナビ%	SPD 探索Lv	SPD ナビ%
MIMIC	3.00	52.16	2.28	14.41
MIMIC-P	2.00	23.62	1.90	11.27
MIMIC-P+S	3.07	45.67	1.94	10.67
人間	2.43	99.45	3.89	47.07
Dumb Monkey	1.93	32.08	1.07	5.75
Smart Monkey	1.71	30.22	1.05	5.77

MIMICは自動ツール中で最深・最高のナビ探索。人間はさらに優位（DA 99.45% / SPD 47.07%）。
95%信頼区間：DAでは人間とほぼ同等、SPDでは人間が有意に高い（区間が非重複）。

有用性評価：概要と実験設定(RQ3 & RQ4)

MinecraftでSOTAエージェント ODYSSEY と比較し、2つの観点から有用性を評価する。

RQ3 タスク完了

時間内の成功率と平均完了時間で評価

RQ4 解の多様性

行動系列のShannon Entropyで評価

MIMIC

Plan-to-Codeでスキル生成 (Mineflayer)
LLM : GPT-4o

ODYSSEY (比較対象・SOTA)

事前コード183スキルから類似度で選択
LLM : MineMA-8B

設定 : 8タスク (Goal-Driven 4 / Time-Limited 4) × 3マップ × 3実行 × 7個性。
環境 : Apple M3 Max · 128GB · macOS 15.2。

タスクスイート：Minecraftの8タスク


ID	タスク	複雑度	MineDojo分類
GD#1	Make 1 Sugar（砂糖を作る）	1	Tech Tree + Harvest
GD#2	Shear 1 Sheep（羊を刈る）	2	Tech Tree + Harvest
GD#3	Cook 1 Meat（肉を調理）	3	Tech Tree + Harvest
GD#4	Obtain 1 Diamond（ダイヤ入手）	4	Harvest
TL#1	Combat 1 Cave Spider（洞窟グモ）	1	Combat
TL#2	Combat 1 Skeleton（スケルトン）	2	Combat
TL#3	Combat 1 Spider（クモ）	3	Combat
TL#4	Survive 1 Day（1日生存）	4	Survival

Goal-Driven：特定アイテムの収集（制限1時間／Obtain 1 Diamondのみ2時間）。

Time-Limited：1ゲーム内日での性能（戦闘・生存）。

RQ3：タスク完了(成功率)


Goal-Driven タスクの成功率 (%)



- MIMIC：全タスク100%成功
- ODYSSEYは複雑化で急落 (Cook 1 Meat は10%)
- Time-Limitedタスクは両者とも100%
- 要因：Hybrid Planner 失敗時に低レベル計画へ動的にフォールバック

RQ3：完了効率と個性の影響


Obtain 1 Diamond：平均完了時間（分）



- 多くのタスクでMIMICが高速
- Diamondのみ ODYSSEY が大幅に速い
- ODYSSEYは単純タスクで不安定
= ベンチマーク過適合の疑い
- 攻撃的個性は戦闘を優先し外れ値
多様なプレイヤー像を再現
- 速度より現実的な行動を反映

RQ4 : 解の多様性(Shannon Entropy)

N-gram-Based Entropy Analysis of Agent Solutions



RQ4：解の多様性(Shannon Entoropy)

タスク	p値	有意差
Make 1 Sugar	0.643	—
Shear 1 Sheep	0.939	—
Cook 1 Meat	0.0132	✓ *
Obtain 1 Diamond	0.0487	✓ *
Combat 1 Cave Spider	0.0220	✓ *
Combat 1 Skeleton	0.0170	✓ *
Combat 1 Spider	0.0166	✓ *
Survive 1 Day	0.0247	✓ *

多様性が高い＝行動が多彩

指標：行動系列の Shannon Entropy (n-gramでも評価)

- 単純タスクは両者ほぼ同等
(多様性の余地が小さい)
- 複雑タスクほど MIMIC が一貫して高い
- 片側対t検定：単純2タスク以外は
すべて $p < 0.05$ で有意 (* 印)

考察：動的コード生成vs事前スキル

MIMIC：動的コード生成

- Plan-to-Codeで実行時に生成
- 新規・想定外タスクに柔軟
- 生成・改良に時間を要する

ODYSSEY：事前スキル呼出

- 即時に実行でき高速
- 大規模Skill Libraryに初期投資
- 新規タスクに弱く精度が低下

限界の実例：「鉄鉱石を精錬」に該当関数がなく、類似度で無関係の「採掘」を繰返し呼出して誤実行。
SkillをMIMICの例示に差し替えると、指定Skill以外のタスクは一切解けなかった。→ 柔軟性と精度

まとめ

課題 既存のテストエージェントは最適経路に偏り、探索行動が単調

提案 MIMIC — 7つの性格特性 + Hybrid Planner + Memory で行動を多様化

結果

- **Dungeon Adventures (小規模)** : 組合せカバレッジ 100% (72/72通り) = 人間テスターに匹敵
- **Shattered Pixel Dungeon (大規模)** : 組合せカバレッジ 0.188% (21,319/1,130万通り) = 自動ツール中で最高・14.46倍
- **Minecraft (vs. ODYSSEY)** : Goalタスク成功率 100%・8タスク中6で解法多様性↑

結論 「性格の違い」をテストカバレッジ向上へ転換する枠組み